NLP 과제_Attention is all you need

220210031 유현우

1. Encoder
   A. Multi-head attention layer
      i. Multi-head attention은 아래 그림에서와 같이 scaled dot-product attention이 병렬적으로 수행되는 구조
      ii. Scale dot-product attention은 다음의 수식으로 설명될 수 있음
      iii. $$\text{Attention}(Q, K, V) = \text{softmax}(\frac{QK^T}{\sqrt{d_k}})V$$
         1. Input feature에 대해서 linear projection을 이용해서 query, key, value를 생성
            A. 코드상
```
Q = self.fc_q(query)
K = self.fc_k(key)
V = self.fc_v(value)
```
         2. 이때 query, key, value의 shape은 [batch size, seq length, hidden dimension]의 형태를 갖고 있음
         3. 수식상에 transposed key가 나타내는 shape은 [batch size, hidden dimension, seq length]의 형태가 됨
         4. 따라서 query와 transposed key간의 행렬곱으로 출력된 energy는 query와 key의 word seq간의 similarity를 의미
         5. 여기에 normalize term으로 $\sqrt{d_k}$ 으로 energy를 나누어 줌. 이때 d_k 는 hidden dimension을 의미
         6. Query와 key간의 similarity로 뽑은 energy를 softmax를 취하여 attention score를 얻음
            A. 코드상
```
energy = torch.matmul(Q, K.permute(0, 1, 3, 2)) / self.scale
attention = torch.softmax(energy, dim = -1)
```
         7. Attention score와 value와의 행렬곱을 통해 attention을 value에 적용하여 출

력

A. 코드상 `x = torch.matmul(self.dropout(attention), V)`

iv. Multi-head attention은 scaled dot-product attention이 병렬적으로 수행되는 구조로 다음의 수식으로 설명

$$\text{MultiHead}(Q,K,V) = \text{Concat}(\text{head}_1,\dots,\text{head}_h)W^O$$
$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V)$$

v. 위의 scale dot-production attention을 병렬적으로 수행해주기 위해 query, key, value의 matrix shape을 [batch size, seq length, hidden dimension]에서 [batch size, seq length, number head, head dimension]으로 변형시켜줌

1. 이는 hidden dimension을 각 head 개수에 따라 head dimension으로 나누어 준 형태

vi. 코드상

```
Q = Q.view(batch_size, -1, self.n_heads, self.head_dim).permute(0, 2, 1, 3)
K = K.view(batch_size, -1, self.n_heads, self.head_dim).permute(0, 2, 1, 3)
V = V.view(batch_size, -1, self.n_heads, self.head_dim).permute(0, 2, 1, 3)
```

vii. 그리고 [batch size, number head, seq length, head dimension]으로 형태를 변환시켜 matrix상의 dim 3,4 ([seq length, head dimension])을 사용해 행렬곱을 수행하여 각 batch 및 number head에 대해 병렬적으로 attention 연산이 수행되도록 함

viii. 최종적으로 한번 더 linear projection으로 embedding한 후 출력

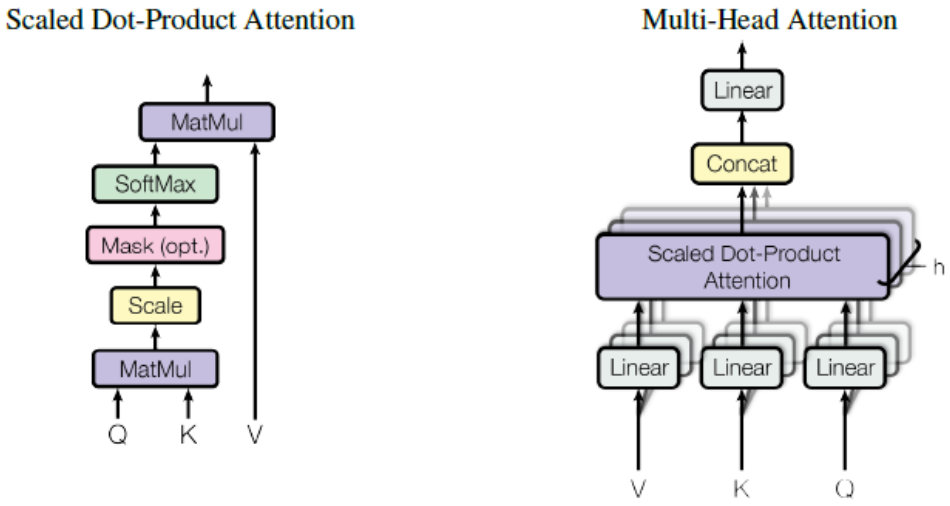

그림 1. scale dot-production attention 및 multi-head attention

B. Position wise feed forward layer

i. Position wise feed forward layer는 network에서 자주 사용되는 layer임

ii. 이는 단순히 각 seq를 linear projection으로 embedding 하고 relu activation을 취한 후 한번 더 linear projection을 이용해서 embedding 해주는 layer

1. 코드상

```
x = self.dropout(torch.relu(self.fc_1(x)))
x = self.fc_2(x)
```

iii. 즉, 그냥 각 seq 별로 두 번의 linear projection을 이용한 embedding을 수행해 주는 것

C. Encoder layer

i. Encoder layer는 위의 multi-head attention layer와 position wise feed forward layer로 이루어짐

ii. Multi-head attention layer -> layer norm -> position wise feed forward -> layer norm으로 구성

iii. 코드상

```
_src, _ = self.self_attention(src, src, src, src_mask)
src = self.self_attn_layer_norm(src + self.dropout(_src))
_src = self.positionwise_feedforward(src)
src = self.ff_layer_norm(src + self.dropout(_src))
```

D. Encoder

i. Source word vector를 input으로 받음

ii. Input된 word vector에 대해서 token embedding 및 position embedding을 수행해야 함

iii. Token embedding은 linear projection 연산을 통해 이루어지고 position embedding은 각 위치에 해당하는 값을 더함

1. 코드상

```
pos = torch.arange(0, src_len).unsqueeze(0).repeat(batch_size, 1).to(self.device)
```

함수를 사용하는데 이는 src_len 길이의 1-d vectore를 생성해주는데 그 값은 index임 이것을 batch size만큼 이어붙여 해당 token과 더함

iv. 코드상

v. `src = self.dropout((self.tok_embedding(src) * self.scale) + self.pos_embedding(pos))`

vi. Token embedding과 position embedding을 수행한 token들을 encoder layer에 input 시켜 encoding 과정을 수행

2. Decoder

A. Decoder layer

i. Decoder에서는 source word vector와 target word vector를 input으로 받음

ii. Decoder layer는 앞서 다룬 encoder에서 사용한 multi-head attention layer 및 feed-forward layer를 마찬가지로 사용

iii. 가장 먼저 embedding된 target token들을 input으로 받아 multi-head attention layer를 통과

1. 이를 통해 token들의 similarity를 고려하여 embedding한 feature를 출력

2. 코드상 `_trg, _ = self.self_attention(trg, trg, trg, trg_mask)`

3. 그리고 layer norm 적용

iv. 그리고 아래 그림의 transformer의 구조를 살펴보면 encoder에서 추출된 source token feature와 decoder에서 input된 target token feature를 multi-head attention의 input으로 받는 것을 알 수 있음

1. 코드상
`_trg, attention = self.encoder_attention(trg, enc_src, enc_src, src_mask)`

2. 이때 source token feature를 key, value로 embedding하고 target token feature를 query로 embedding 함

3. 이를 통해 target token들이 source token들간의 관계를 고려하여 원하는 출력값을 도출할 수 있는 구조를 가짐

4. 그리고 layer norm을 적용하여 출력

v. 마지막으로 encoder block에서와 마찬가지로 feed-forward layer를 통과시킨 후 linear projection을 이용해 logit을 출력하고 이를 softmax를 적용하여 최종 prediction probabilities를 출력

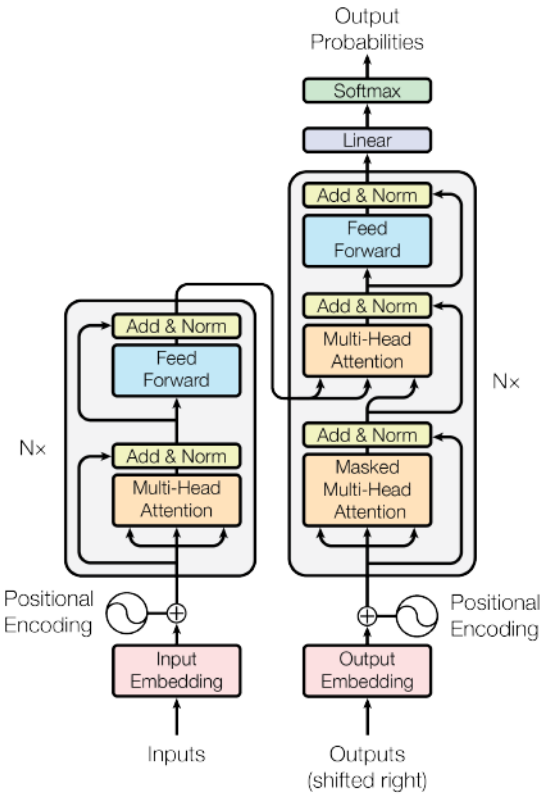

그림 2. Transformer architecture

3. Train

   A. 위에서 다룬 transformer encoder-decoder 구조를 이용해서 learning rate 0.0005, optimizer는 ADAM, loss는 cross entropy loss를 사용하여 10 epoch를 학습

   B. 학습 결과는 아래 그림과 같고 epoch에 따라 train loss 및 validation loss가 줄어드는 것을 확인할 수 있음

```
Epoch: 01 | Time: 0m 17s
        Train Loss: 4.238 | Train PPL:  69.251
         Val. Loss: 3.024 |  Val. PPL:  20.566
Epoch: 02 | Time: 0m 16s
        Train Loss: 2.821 | Train PPL:  16.796
         Val. Loss: 2.312 |  Val. PPL:  10.093
Epoch: 03 | Time: 0m 16s
        Train Loss: 2.235 | Train PPL:   9.347
         Val. Loss: 1.981 |  Val. PPL:   7.253
Epoch: 04 | Time: 0m 17s
        Train Loss: 1.880 | Train PPL:   6.555
         Val. Loss: 1.802 |  Val. PPL:   6.065
Epoch: 05 | Time: 0m 17s
        Train Loss: 1.635 | Train PPL:   5.129
         Val. Loss: 1.702 |  Val. PPL:   5.485
Epoch: 06 | Time: 0m 17s
        Train Loss: 1.444 | Train PPL:   4.236
         Val. Loss: 1.649 |  Val. PPL:   5.200
Epoch: 07 | Time: 0m 17s
        Train Loss: 1.293 | Train PPL:   3.643
         Val. Loss: 1.614 |  Val. PPL:   5.024
Epoch: 08 | Time: 0m 17s
        Train Loss: 1.165 | Train PPL:   3.205
         Val. Loss: 1.618 |  Val. PPL:   5.042
Epoch: 09 | Time: 0m 17s
        Train Loss: 1.055 | Train PPL:   2.872
         Val. Loss: 1.629 |  Val. PPL:   5.099
Epoch: 10 | Time: 0m 17s
        Train Loss: 0.961 | Train PPL:   2.615
         Val. Loss: 1.642 |  Val. PPL:   5.163
```

4. Inference

   A. Train 된 model weight를 불러와서 영어를 독일어로 번역 수행

   B. 실험 결과는 아래 그림에서와 같다.

      i. src = ['eine', 'mutter', 'und', 'ihr', 'kleiner', 'sohn', 'genießen', 'einen', 'schönen', 'tag', 'im', 'freien', '.']

      ii. trg = ['a', 'mother', 'and', 'her', 'young', 'song', 'enjoying', 'a', 'beautiful', 'day', 'outside', '.']

      iii. 에 대해서

      iv. predicted trg = ['a', 'mother', 'and', 'her', 'son', 'enjoying', 'a', 'beautiful', 'day', 'outdoors', '.', '<eos>'] 출력

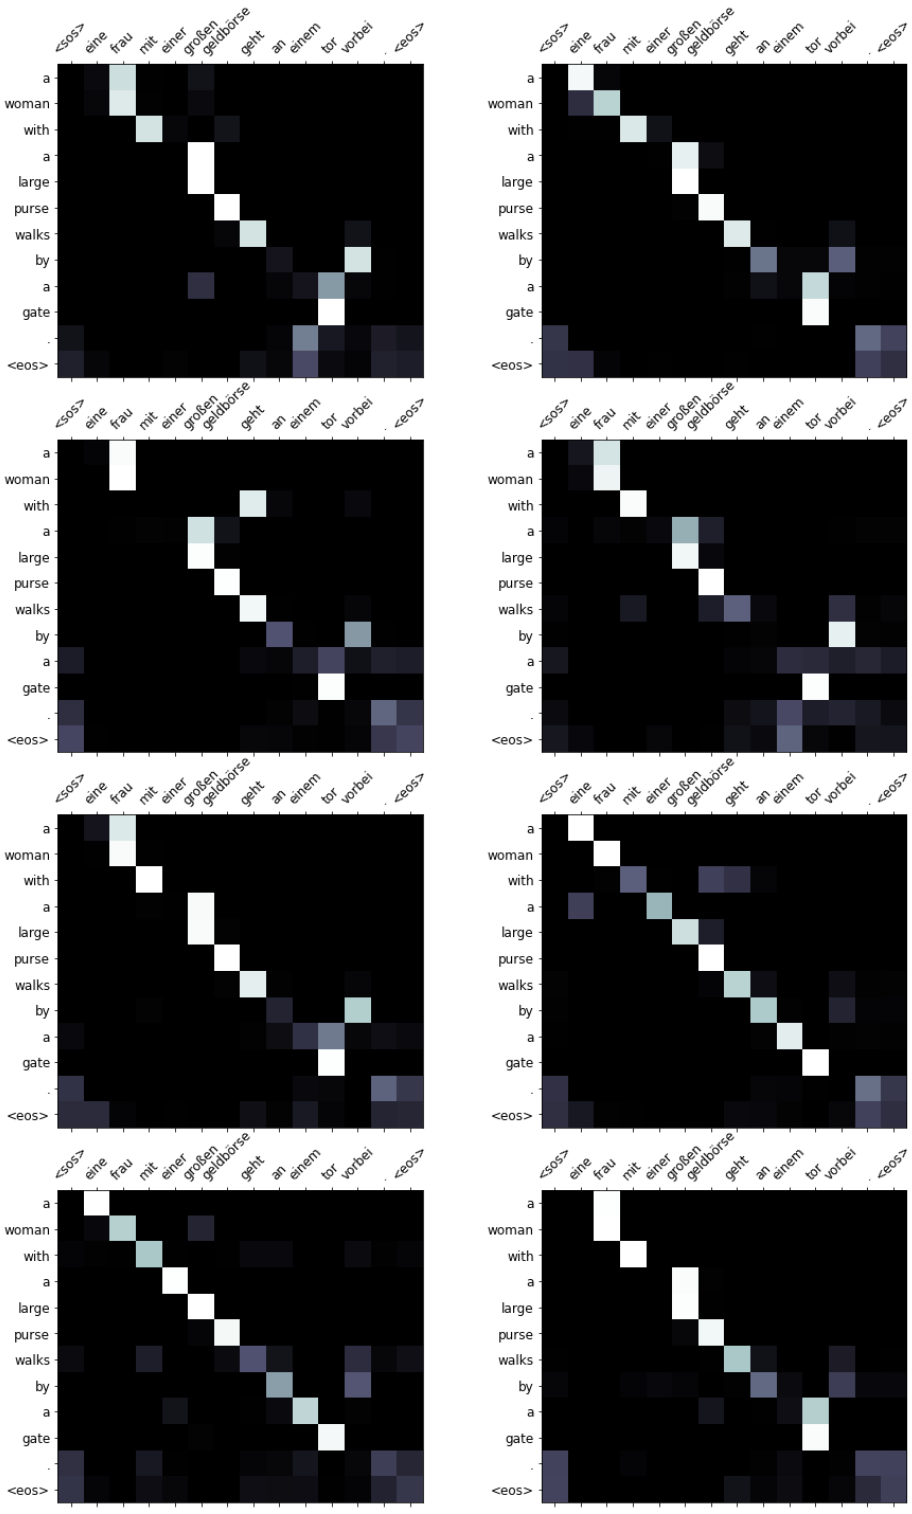
<sos> eine frau mit einer großen geldbörse geht an einem tor vorbei . <eos>
a woman with a large purse walks by a gate . <eos>